DATA BATTLE @ IAPAU

Vous souhaitez tester de nouvelles idées,

contacter et recruter de jeunes talents ?

Confiez l'une de vos problématiques data à plusieurs équipes d'étudiants coachées par des experts durant 30 jours lors du Data BATTLE sur l'Intelligence Artificielle IA PAU

contact@iapau.org

Qui sommes-nous ?

L'association IA Pau créée en 2019, rassemble autour du thème de l'IA, des professionnels palois et tarbais. Son objectif est de vulgariser et partager les connaissances autour de ce progrès majeur du XXIème siècle qui suscite de nombreuses interrogations scientifiques, technologiques, éthiques, et démocratiques. Son activité et ses événements à portée nationale participent à la fédération du territoire et des acteurs nationaux autour des problématiques Data Science. Enfin, elle est facilitatrice de rencontres entre entreprises et jeunes talents. Elle a pour ambition de créer des festivals d'IA incontournables au niveau national. https://iapau.org/

Les Data Battles sont co-organisés avec la **Technopole Hélioparc** : Au cœur de Pau, à deux pas du campus universitaire, de plusieurs écoles d'ingénieurs et de l'Ecole Supérieure de Commerce, la technopole Hélioparc est un lieu privilégié pour la création et le développement d'activités innovantes. www.helioparc.fr

Depuis 2018, l'association IA Pau organise des compétitions sur un principe qui a fait ses preuves : des étudiants de toute la France encadrés par des experts, étudient pendant deux jours un problème lié à des données avant de les défendre devant un Jury **pour disputer les 6000 € de prix!**

Découvrez le Data Battle IA PAU : Un Terrain Propice à l'Acculturation de l'IA et à l'Exploitation de Vos Données

Le Data Battle IA PAU a l'ambition de transformer votre paysage de l'Intelligence Artificielle en offrant un environnement unique pour l'acculturation de vos équipes aux enjeux de l'exploitation de vos données, accompagné par des spécialistes du traitement des données et de l'IA, qu'elle soit générative ou décisionnelle.

Pourquoi Participer ?

1. **Acculturation et exploration**
    - **Pour vos équipes :** Immergez vos équipes dans un environnement

dynamique et stimulant, les exposant aux meilleures pratiques en matière de traitement des données et d'IA, avec des spécialistes du domaine, des experts industriels et scientifiques qui partagent leur temps pour challenger les étudiants et transmettre leurs dernières pratiques.

2. **Collaboration et Innovation :**
   - **Un Écosystème d'Excellence :** Collaborez le temps d'un weekend avec une centaines d' étudiants ingénieurs des formations françaises en IA les plus prestigieuses. Par équipe de 4 à 6, ces jeunes talents mettent leur énergie et leur créativité au service de 3 projets, apportant ainsi des approches différentes et des solutions novatrices et pertinentes.
   - **Projets Concrets :** proposez des problématiques réelles de votre organisation et voyez vos données traitées et exploitées pour apporter des réponses innovantes et efficaces.
3. **Réseautage et Partage d'Expériences :**
   - **Échange de Savoir-Faire :** Bénéficiez des retours d'expérience et des conseils avisés d'autres entreprises et professionnels du secteur. Apprenez des succès et des défis rencontrés par vos pairs.
   - **Visibilité et Reconnaissance :** Gagnez en visibilité dans la communauté de l'IA et positionnez votre entreprise comme un acteur innovant et engagé dans l'ère du numérique.
4. **Ressources et Opportunités de Recrutement :**
   - **Découverte des Talents :** Le Data Battle est une opportunité unique pour rencontrer les étudiants les plus prometteurs du domaine de l'IA. Identifiez et recrutez les talents de demain en proposant des stages, des alternances, et même des futures embauches. Ces rencontres peuvent être déterminantes pour votre stratégie de recrutement et pour renforcer vos équipes avec des profils d'excellence.
   - **Accès à des ressources dédiées :** Profitez de ressources spécialisées et d'un soutien personnalisé pour maximiser l'impact de votre participation au Data Battle.
5. **Livrables Concrets pour l'Entreprise :**
   - **Prototypes Fonctionnels :** Assister au démonstration des prototypes fonctionnels développés par les étudiants pour répondre à vos problématiques spécifiques. Ces prototypes peuvent être la base de futurs produits ou services.
   - **Scénarios de Traitement :** Explorez différents scénarios de traitement proposés par les étudiants, offrant des approches variées et innovantes pour résoudre vos défis.
   - **Pitch au Profil Startup :** Assistez à des présentations de type startup pitch, où les étudiants présentent leurs solutions de manière concise et impactante, prêtes à être déployées ou à attirer des investissements.

Envie de concret ? Revivez la Data Battle IA Pau 2025 sur notre chaine youtube IA Pau et retrouvez **en bas de ce document les entreprises participantes des 6 dernières années avec leurs sujets**.

Data Battle IA Pau : modalités de dépôt des projets

Un dépôt de sujet comprend :

- une description sous la forme de une à deux pages présentant l'entreprise porteuse du projet, le contexte du challenge, la problématique et les objectifs, un Jeu de données, les perspectives éventuelles du challenge.
- un jeu de données dans un format utilisable par les étudiants pour une tâche de machine learning.
- Le porteur du projet devra accompagner les étudiants durant les 2 journées du Data Battle et participer à la sélection des vainqueurs.

La mise en place peut nécessiter un accompagnement de la part de l'association IA Pau pour valider le projet et effectuer une mise en forme (anonymisation par exemple) et un contrôle au niveau de la qualité des données fournies :

- la première étape consiste à valider la faisabilité du projet (intervention gratuite) - la seconde étape consiste à rédiger la description du projet, à récupérer, formater et contrôler les données fournies.

La Formule :

8000€ pour les organisations de plus de 15 salariés
4000 € pour les organisations de moins de 15 salariés
Gratuit pour les associations reconnues d'utilité publique

Ce cadre budgétaire nous permet de financer l'organisation et les prix (6000 euros) pour les étudiants. donne également droit à la campagne de communication en tant que sponsor du festival IA Pau : nos actions de communication comprennent plusieurs campagnes mailings, de nombreuses publications sur les réseaux sociaux dont deux posts présentant votre entreprise à nos communautés Linkedin et Twitter (1300 membres), la présence de votre logo sur toutes les pages web liées à l'évènement, la visibilité auprès des écoles de la data.

L'alternative Data challenge : Envie de plus ? Le Data Challenge est une **compétition sur deux jours** qui a lieu chaque année début décembre. Contactez-nous pour en savoir plus!

Data Battle IA Pau : comment ça se passe le jour J ?

- D'abord, vous pitchez votre projet en visio devant les étudiants. et nous leur fournissons la description du sujet.
- Et c'est parti! Nous fournissons les données aux étudiants, et les accompagnons pendant la construction de leurs solutions. Nous vous conseillons de vous rendre ponctuellement disponible pour encourager et discuter avec les étudiants afin de

répondre à leurs questions ou d'orienter leurs travaux. C'est aussi la meilleure manière de les connaître et de repérer les pépites. La réalisation finale est généralement un démonstrateur POC résolvant la problématique fournie.
- Évaluation et remise des prix ! Les équipes pitchent leurs résultats et un jury d'experts d'IAPAu et d'extérieurs, auquel vous participerez, décide des équipes gagnantes. Consultez les finales passées sur notre chaine youtube IAPau .

Et après... tout reste à écrire. Vous récupérez le code des étudiants et pouvez continuer votre collaboration avec eux. Une occasion de trouver de futurs collaborateurs.

Data Battle et GreenAI

L'intelligence artificielle attire par ses promesses de rentabilité, de nouvelles possibilités techniques, et la génération automatique de connaissances. Son développement à grande vitesse s'accompagne de questionnements sur ses impacts environnementaux, sociétaux. Alors que notre décennie sera cruciale pour le sort de l'humanité, IA Pau participe à l'effort commun pour gérer la transition environnementale

- les étudiants reçoivent une formation sur les conséquences de l'IA et du numérique, - une plateforme de diagnostic automatique et d'analyse multicritère (Bilan carbone, ressources abiotiques, eau) des solutions IA est utilisée pendant la compétition - l'impact environnemental et sociétal est pris en compte par des membres du jury experts en GreenIT de la communauté CNRS ECOINFO.

Avec IA Pau, conjuguons transition environnementale et data science !

Data Battle IA Pau : projets des précédentes sessions

Boavizta : Identifier un modèle NLP présentant le moins d'impact environnemental
Objectifs : L'objectif est de construire un modèle de NLP avec le coût environnemental le plus bas possible. Le projet concerne la tâche de classification de sentiment, c'est à dire de classer des phrases selon que les sentiments décrits sont positifs ou négatifs. Cette tâche a l'avantage d'être relativement connue, et porte sur de nombreuses applications de la vie réelle. Il est demandé d'explorer l'état de l'art et trouver des modèles qui offrent des compromis précision/impact plus intéressants que les modèles classiquement utilisés. Tout modèle de NLP peut être testé (TF-IDF, embedding based classifier, LSTM, BERT), ainsi que les modèles pré-entraînés (exclusion des modèles déjà entraînés pour la classification de sentiments).
Jeu de données : Les données se composent d'un sous-ensemble de 30000 critiques de films extraites du site IMDb. Un second corpus wikitext est fourni pour apprendre son propre

modèle de langage ou plongement lexical. L'usage de ce second corpus est optionnel.

Green AI UPPA : Optimisation d'une application de sensibilisation à l'environnement
Objectifs : l'équipe GreenAI UPPA développe depuis plusieurs mois une application de sensibilisation à l'environnement sur https://la-derniere-bibliotheque.org/. L'objectif du challenge est d'améliorer le modèle de NLP utilisé par l'application pour ajouter de la pertinence au moteur de recherche et proposer automatiquement des tags lors de l'ajout de contenus. Concernant le moteur de recherche, il s'agit d'une part d'améliorer la pertinence des résultats, étant donné la requête saisie par l'utilisateur, mais également d'optimiser et de renseigner l'énergie consommée lors de la requête. Concernant la proposition de tags lors d'une nouvelle saisie, il s'agit d'entraîner des classifieurs à partir des différents modèles de NLP sur les données de l'application.
Jeu de données : mise à disposition d'un dépôt github contenant le code open-source du projet en ligne la-derniere-bibliotheque.org, des fichiers relatifs à l'évaluation du moteur de recherche (un fichier contenant 20 requêtes et contenus associés à chaque requête, un script python pour évaluer le top5, top3, et top1 de l'algorithme de recherche), les tweets utilisés pour entraîner le modèle fasttext actuellement en production.

Les petits bots : Anonymisation des données personnelles
Objectifs : l'objectif est d'anonymiser les messages des utilisateurs; la version idéale devrait fonctionner en 2 étapes : identifier automatiquement les mots ou groupes de mots qui sont des informations à caractère personnel ou sensible dans les messages envoyés aux chatbots, puis anonymiser ces messages en cachant ces mots ou groupes de mots. En fonction des contraintes techniques rencontrées, il est possible d'imaginer une première version où les 2 étapes seraient : identifier automatiquement les messages comportant des informations à caractère personnel ou sensible, puis les supprimer. Cette version n'est pas optimale, puisque l'objectif est de garder tous les messages non compris afin d'alimenter le chatbot lors du processus "Entraînement".
Jeu de données : 2 sets de données fournies : les messages des habitants de la ville de Clichy et les messages des collaborateurs travaillant à la Gendarmerie Nationale. Tous ces messages ont été labellisés (identification des messages qui possèdent des informations personnelles, et au sein de ces messages, tag des mots qui posent problème). Un fichier .xlsx contenant les éléments suivants est fourni : un ID, une query (la question posée par l'utilisateur), un drapeau indiquant si la question détient des éléments sensibles ou non; un autre .xlsx contenant uniquement les phrases contenant des éléments sensibles (en gras) est également disponible.

API Conseil : classification des brevets
Objectifs : construire un algorithme capable de déterminer 2-3 classifications les plus probables à partir de la partie revendication (seulement 500-1000 mots) d'une demande de brevet. Un point crucial et original sera de construire un modèle interprétable dans le sens où ses décisions pourront être facilement explicitées par un lien direct avec les données.
Jeu de données : un fichier texte structuré comprenant plusieurs publications de brevet, avec la revendication et la classification correspondantes.

Cap Gemini : recherche de pages contenant des zones à intérêt dans un document PDF

Objectifs : construire une solution qui recherche dans des documents pdf de plusieurs centaines de pages, les pages contenant les ZOI (Zone Of Interest) concernant les caractéristiques de pression des fluides (une fois trouvées, les données seront extraites manuellement).
Jeu de données : il est composé de 150 documents PDF ; chaque PDF contient une page et la solution proposée devra définir s'il s'agit d'une zone d'intérêt ou non ; parmi ces 150 documents, 50 contiennent une ZOI et 100 n'en contiennent pas ; tous les documents sont extraits du jeu de données original.

Surf Rider : détection et classification de déchets dans des images et vidéos ***Objectifs :*** construire un algorithme ou retravailler l'existant pour lui permettre de détecter et classer dans 10 catégories les déchets détectés dans des images ou vidéos. Comparer les performances de l'ancien et du nouveau modèle. L'algorithme doit fonctionner sur mobile : il doit donc rester léger tout en étant performant.
Jeu de données : une bibliothèque d'images et vidéos étiquetées avec bounding boxes.

Elan Béarnais Pau Lacq Orthez (Pau) : team performance prediction ***Objectifs :*** construire un algorithme capable de suggérer à l'utilisateur à tout moment durant un match, une ou plusieurs solutions de coaching en fonction de l'évolution du score, du temps restant à jouer, et des joueurs présents sur le terrain.
Jeu de données : un historique de plus de 28 000 événements observés durant plusieurs matchs.

Lo Congres (Pau) : analyse morpho-syntaxique en occitan
Objectifs : réaliser un PoS-tagger pour des textes de corpus, à partir de lexiques très complets et de corpus non annotés : à partir d'une phrase, l'algorithme doit être capable de la découper en unités et d'attribuer une étiquette morpho-syntaxique (verbe, nom propre masculin singulier,…) pour chaque unité.
Jeu de données : plusieurs structures de données dont une bibliothèque des catégories grammaticales, un lexique de 1 400 000 formes fléchies en occitan gascon (verbes conjugués, noms et adjectifs déclinés, etc.), des corpus annotés et non annotés .

Téréga (Pau) : prévisions des demandes clients
Objectifs : construire un algorithme capable de prévoir les demandes de capacités de transport de gaz des clients dans les points de stockage et les points d'interfaces entre deux réseaux.
Jeu de données : un historique des demandes réelles des clients depuis 2016 et un historique des variables pouvant influencer ces demandes depuis 2016.

Total Energies (Pau) : Duplicate image detection
Objectifs : élaborer des algorithmes pour déterminer rapidement si le contenu visuel d'une image est identique ou similaire à d'autres images (near duplicates) et pour trouver si une image appartient à une autre image (template matching).
Jeu de données : une bibliothèque d'images dont certaines sont identiques ou très proches

(near duplicates), une bibliothèque d'images contenant d'une part les images originales et d'autre part les sous-images (templates).

Capgemini (Pau) : pronostics sportifs (coupe du monde de rugby)
Objectifs : à l'aide d'outils d'apprentissage supervisé, vous devrez prédire les résultats de toutes les rencontres de la Coupe du Monde 2019. L'objectif final sera de déterminer le Champion du Monde et le score de la finale.
Jeu de données : résultats des rencontres ayant opposées chaque équipe depuis le 1er janvier 2015 jusqu'au 10 septembre 2019.

DataPink (Lyon) : segmentation sémantique d'images satellites
Objectifs : à partir du framework opensource RoboSat.pink (édité par DatPink), améliorer la qualité de reconnaissance des patterns (par exemple en respectant la topologie), ou les performances logicielles sur la phase de training et lors de l'inférence.
Jeu de données : 40 000 images (définition 512x512), avec étiquettes d'occupation du sol calés sur chaque image.

Euralis (Pau) : assistant vocal intelligent dédié aux questions techniques agricoles
Objectifs : à partir d'une base de données d'images, de conversations, ainsi que des pointeurs vers des sites de conseils agronomiques, construire une base de connaissance constitué de couples (images, texte) contenant les images collectées et le texte associé contenant la réponse au problème, puis mettre en place un algorithme capable de suggérer à l'utilisateur une (ou plusieurs) réponses associées à une nouvelle image. ***Jeu de données :*** un dossier WhatsApp de 2 ans d'historiques de discussions, un fichier métier contenant plus de 500 questions des techniciens, les réponses techniques, des annotations, des pointeurs vers des sites de conseils agronomiques.

Kappsports (Bidart) : évaluer les coureurs de sports d'endurance
Objectifs : attribuer un score à chaque sportif de la base fournie, traduisant son niveau sur chacune des disciplines (course sur route, trail, cyclisme, triathlon...), à partir du niveau de performance de l'ensemble des participants à l'épreuve; objectifs finaux : donner une idée générale du niveau d'une course, attribuer des évaluations aux coureurs (comme pour le tennis), leur permettre de suivre leur évolution, se comparer.
Jeu de données : base détaillée de tous les résultats, avec les informations de distance et type d'épreuve.

La Fibre64 (Pau) : Détermination d'emplacements appropriés pour couvrir une zone en 4G
Objectifs : entre 2 points, trouver un itinéraire routier sans rupture de la couverture 4G; entre 2 points, déterminez les endroits les plus adaptés pour implanter un ou plusieurs pylônes de téléphonie mobile afin que le chemin soit le plus court possible. ***Jeu de données :*** un modèle numérique de terrain (BD_ALTI), tracé des routes départementales, implantation et couverture des 4 principaux opérateurs.

Capgemini et Safran Helicopter Engines : détection d'anomalies moteurs ***Objectifs :*** à partir des paramètres fournis dans les données, détection d'anomalie non supervisée, en créant des descripteurs pertinents et adaptés aux modèles de machine learning utilisés.

Jeu de données : un historique des vols de 24 hélicoptères sur l'année 2017.

Elan Béarnais Pau-Orthez (Pau) : assistant pour recruter les meilleurs joueurs ***Objectifs :*** identifier le profil des joueurs performants pour savoir lesquels sont disposés à avoir un bon impact dans le championnat ; rechercher des similitudes entre les joueurs afin de pouvoir « prédire » le futur d'un joueur à partir de ses saisons passées. ***Jeu de données :*** l'historique en carrière de l'ensemble des joueurs ayant évolué en première division entre 2005 et 2018.

IPREM (Pau, Université) : détection de contrefaçon d'un vin
Objectifs : pouvoir différencier des vins provenant de pays différents; pouvoir identifier l'origine (continent, pays, région) d'un vin inconnu (contrefaçon); identifier des critères discriminants pour (signature de) certains Pays / Régions / Continents. ***Jeu de données :*** les concentrations élémentaires en ppb (ug /L) et les rapports isotopiques de vins provenant de continents, pays et régions différentes.

Comm.Agglo. Pau (Pau) : outil de recherche intelligente pour les archives communautaires
Objectifs : découpage et regroupement lexical de toutes les données archivées; étude d'un outil de navigation et recherche intelligent des délibérations.
Jeu de données : une liste codifiée de délibérations.

Faster Horses (Pau) : possibilités et risques liés à l'exploitation des données pour les élèves
Objectifs : concevoir une activité qui pourra servir l'exploitation des données des élèves, tout en leur montrant la richesse des informations qui peuvent être obtenues par l'analyse de données qui peuvent paraître très limitées et fragmentées. Par exemple, créer un algorithme qui permette de reconnaître des communautés de personnes, à partir de données de localisation d'un groupe de collégiens.
Jeu de données : positions GPS de 36 collégiens sur une période.

Universal Software (Cameroun) : IA pour aide au diagnostic médical ***Objectifs :*** concevoir un outil informatique d'assistance au diagnostic médical, qui va permettre de réduire les erreurs de diagnostic et prendre en compte tous les traitements antérieurs et actes médicaux du patient.
Jeu de données : données tabulaires : maladies, antécédents, motifs de consultation (les symptômes), liste des examens, dossiers patients.